



Ονοματεπώνυμο: Ζαχαρίας Κυριακάας (22390114)

Μάθημα: **Διαχείριση Δεδομένων Μεγάλης Κλίμακας (ICE-359)**

Ημερομηνία παράδοσης: 11/6/2026

Εξάμηνο: 8^ο

Jupyter notebook: https://colab.research.google.com/drive/1ixlckVw_2tmqWcGBYjvQYkXntIhLpEjY?usp=sharing

Github: <https://github.com/Zachos-K/Bank-Marketing-Project>

Big Data & Data Mining Project

Πρόβλεψη Εγγραφής Πελατών σε Τραπεζική Προθεσμιακή Κατάθεση

Dataset: Bank Marketing Dataset

Περιεχόμενα

1. Εισαγωγή	3
2. Περιγραφή Dataset	3
3. Data Understanding & Preprocessing.....	4
4. Exploratory Data Analysis	4
5. Classification Models	7
6. Model Evaluation	7
7. Advanced Technique: K-Means Clustering	9
8. Big Data Approach με PySpark	10
9. Σύγκριση Μοντέλων	10
10. Συμπεράσματα.....	11
Βιβλιογραφία	11


1. Εισαγωγή

Η παρούσα εξαμηνιαία εργασία αφορά την υλοποίηση ενός end-to-end συστήματος ανάλυσης δεδομένων με τεχνικές Data Mining και Big Data Processing. Το θέμα που επιλέχθηκε είναι η πρόβλεψη του αν ένας πελάτης τραπεζικού οργανισμού θα αποδεχθεί την προσφορά για προθεσμιακή κατάθεση. Το πρόβλημα είναι δυαδικής ταξινόμησης, καθώς η μεταβλητή στόχος παίρνει δύο τιμές: yes ή no.

Η εργασία καλύπτει όλα τα βασικά στάδια ενός έργου ανάλυσης δεδομένων: κατανόηση του dataset, καθαρισμό, feature engineering, exploratory data analysis, εφαρμογή αλγορίθμων ταξινόμησης, αξιολόγηση μοντέλων, clustering και Big Data προσέγγιση με PySpark.

2. Περιγραφή Dataset

Το Bank Marketing Dataset προέρχεται από δεδομένα τηλεφωνικών καμπανιών marketing πορτογαλικού τραπεζικού ιδρύματος. Στόχος είναι να προβλεφθεί αν ο πελάτης θα εγγραφεί σε τραπεζική προθεσμιακή κατάθεση. Το αρχείο bank-additional-full.csv περιλαμβάνει 41.188 εγγραφές και 20 input variables, ενώ η μεταβλητή στόχος είναι η y.



	age	job	marital	education	default	housing	loan	contact	month	day_of_week	...	campaign	pdays	previous	poutcome	emp.var.rate	cons.price.idx	cons.conf.idx	euribor3m	nr.employed	y
0	56	housemaid	married	basic.4y	no	no	no	telephone	may	mon	...	1	999	0	nonexistent	1.1	93.994	-36.4	4.857	5191.0	no
1	57	services	married	high.school	unknown	no	no	telephone	may	mon	...	1	999	0	nonexistent	1.1	93.994	-36.4	4.857	5191.0	no
2	37	services	married	high.school	no	yes	no	telephone	may	mon	...	1	999	0	nonexistent	1.1	93.994	-36.4	4.857	5191.0	no
3	40	admin.	married	basic.6y	no	no	no	telephone	may	mon	...	1	999	0	nonexistent	1.1	93.994	-36.4	4.857	5191.0	no
4	56	services	married	high.school	no	no	yes	telephone	may	mon	...	1	999	0	nonexistent	1.1	93.994	-36.4	4.857	5191.0	no


Εικόνα 1. Πρώτες γραμμές του Bank Marketing Dataset όπως φορτώθηκαν στο Jupyter Notebook.

Οι μεταβλητές περιλαμβάνουν δημογραφικά στοιχεία, οικονομικά χαρακτηριστικά, στοιχεία επικοινωνίας και πληροφορίες προηγούμενων καμπανιών. Παραδείγματα μεταβλητών είναι: age, job, marital, education, housing, loan, contact, campaign, pdays, previous και poutcome.

Κατηγορία	Παραδείγματα μεταβλητών	Περιγραφή
Δημογραφικά	age, job, marital, education	Περιγράφουν βασικά χαρακτηριστικά πελάτη.
Οικονομικά	housing, loan, default	Σχετίζονται με δάνεια και οικονομικές υποχρεώσεις.
Καμπάνια	contact, month, campaign, pdays, previous	Περιγράφουν την επικοινωνία της τράπεζας με τον πελάτη.
Target	y	Δηλώνει αν ο πελάτης αποδέχθηκε την προθεσμιακή κατάθεση.

3. Data Understanding & Preprocessing

Αρχικά εξετάστηκαν το μέγεθος του dataset, οι τύποι των μεταβλητών και η κατανομή της μεταβλητής στόχου. Έγινε έλεγχος για missing values και διερευνήθηκαν οι κατηγορικές τιμές, όπως η τιμή unknown, η οποία διατηρήθηκε ως ειδική κατηγορία.



Εικόνα 2. Έλεγχος missing values και αρχική κατανομή της μεταβλητής στόχου.

Η μεταβλητή duration αφαιρέθηκε από τα μοντέλα, επειδή είναι γνωστή μόνο μετά το τέλος της τηλεφωνικής κλήσης. Η χρήση της θα μπορούσε να οδηγήσει σε data leakage και τεχνητά αυξημένη απόδοση. Για την προετοιμασία των δεδομένων εφαρμόστηκαν One-Hot Encoding στις κατηγορικές μεταβλητές και StandardScaler στις αριθμητικές μεταβλητές.

- Μετατροπή του target y σε 0/1.
- Αφαίρεση της duration για αποφυγή data leakage.
- Feature engineering: age_group, was_contacted_before, many_contacts.
- IQR clipping για περιορισμό ακραίων τιμών.
- Train-test split με stratification.


4. Exploratory Data Analysis

Στο στάδιο EDA δημιουργήθηκαν γραφήματα για την κατανομή της μεταβλητής στόχου, την κατανομή ηλικίας, το ποσοστό επιτυχίας ανά επάγγελμα, το ποσοστό επιτυχίας ανά μήνα επικοινωνίας και heatmap συσχετίσεων για τις αριθμητικές μεταβλητές.




Εικόνα 3. Κατανομή της μεταβλητής στόχου y .

Παρατηρείται ανισορροπία στις κλάσεις, καθώς οι περισσότεροι πελάτες δεν αποδέχονται την προσφορά. Αυτό επηρεάζει την αξιολόγηση των μοντέλων, επειδή το Accuracy από μόνο του μπορεί να είναι παραπλανητικό.




Εικόνα 4. Κατανομή ηλικίας πελατών.

Η κατανομή ηλικίας δείχνει ποιες ηλικιακές ομάδες εμφανίζονται συχνότερα στο dataset και βοηθά στην κατανόηση του προφίλ των πελατών της καμπάνιας.



Εικόνα 5. Ποσοστό αποδοχής της προσφοράς ανά επάγγελμα.

Το γράφημα βοηθά στον εντοπισμό επαγγελματικών ομάδων με υψηλότερη ή χαμηλότερη ανταπόκριση στην τραπεζική καμπάνια.



Εικόνα 6. Συσχέτιση αριθμητικών μεταβλητών.

Το correlation heatmap χρησιμοποιείται για να εντοπιστούν πιθανές σχέσεις μεταξύ αριθμητικών χαρακτηριστικών και να υποστηριχθεί η κατανόηση των δεδομένων πριν την εφαρμογή των μοντέλων.

5. Classification Models

Για το πρόβλημα ταξινόμησης εφαρμόστηκαν τέσσερα μοντέλα, ώστε να υπάρχει επαρκής σύγκριση διαφορετικών προσεγγίσεων: Decision Tree, Linear SVM, Naive Bayes και Neural Network/MLP. Η χρήση περισσότερων από δύο μοντέλων ενισχύει την αξιοπιστία της σύγκρισης.


Μοντέλο	Τύπος	Πλεονέκτημα	Περιορισμός
Decision Tree	Tree-based	Ερμηνεύσιμο και γρήγορο	Κίνδυνος overfitting
Linear SVM	Margin-based	Κατάλληλο για υψηλές διαστάσεις	Λιγότερο ερμηνεύσιμο
Naive Bayes	Probabilistic	Γρήγορο και απλό baseline	Υπόθεση ανεξαρτησίας χαρακτηριστικών
Neural Network	Non-linear	Μπορεί να μάθει σύνθετα patterns	Χρειάζεται προσεκτική ρύθμιση

6. Model Evaluation

Τα μοντέλα αξιολογήθηκαν με Accuracy, Precision, Recall, F1-score, Confusion Matrix και ROC-AUC. Επειδή η κλάση yes είναι μικρότερη από την κλάση no, το Accuracy δεν αρκεί μόνο του. Για αυτό δόθηκε ιδιαίτερη σημασία στο F1-score και στο ROC-AUC.


	Model	Accuracy	Precision	Recall	F1-score	ROC-AUC
0	Decision Tree	0.831998	0.363309	0.653017	0.466872	0.789248
1	Linear SVM	0.832119	0.362538	0.646552	0.464576	0.800495
2	Naive Bayes	0.802501	0.317684	0.656250	0.428120	0.778497
3	Neural Network	0.900340	0.670927	0.226293	0.338437	0.802866

Πίνακας 1. Συγκριτικά αποτελέσματα μοντέλων ταξινόμησης.



Εικόνα 7. Confusion Matrix του Decision Tree.

Το confusion matrix δείχνει πόσες προβλέψεις έγιναν σωστά και πόσες λανθασμένα για τις δύο κλάσεις. Είναι ιδιαίτερα χρήσιμο επειδή το dataset είναι imbalanced.




Εικόνα 8. ROC Curve του Decision Tree.


Η ROC Curve δείχνει τη διαχωριστική ικανότητα του μοντέλου. Όσο μεγαλύτερο είναι το ROC-AUC, τόσο καλύτερα διαχωρίζει το μοντέλο τους πελάτες που αποδέχονται από αυτούς που δεν αποδέχονται την προσφορά.

7. Advanced Technique: K-Means Clustering

Ως advanced technique χρησιμοποιήθηκε K-Means Clustering. Στόχος ήταν η τμηματοποίηση των πελατών σε ομάδες με παρόμοια χαρακτηριστικά. Τα clusters συγκρίθηκαν με βάση το μέσο subscription rate, ώστε να εντοπιστούν ομάδες πελατών με υψηλότερη ή χαμηλότερη πιθανότητα αποδοχής της προσφοράς.



Εικόνα 9. Elbow Method για επιλογή αριθμού clusters.



Εικόνα 10. Οπτικοποίηση K-Means clusters με PCA.

	cluster	count	subscription_rate
0	0	18066	0.048932
1	1	13499	0.244537
2	2	9623	0.047283

Πίνακας 2. Μέσο subscription rate ανά cluster.

Η σύγκριση των clusters ως προς το μέσο target βοηθά στον εντοπισμό ομάδων πελατών με υψηλότερη πιθανότητα ανταπόκρισης.

8. Big Data Approach με PySpark

Η Big Data προσέγγιση υλοποιήθηκε με PySpark. Δημιουργήθηκε pipeline που περιλαμβάνει StringIndexer, OneHotEncoder, VectorAssembler και RandomForestClassifier. Παρότι το dataset δεν είναι εξαιρετικά μεγάλο, η χρήση PySpark δείχνει πως η ίδια μεθοδολογία μπορεί να κλιμακωθεί σε μεγαλύτερα τραπεζικά δεδομένα.


	Model	Accuracy	F1-score	ROC-AUC
0	Spark Random Forest	0.899525	0.871702	0.796055

Εικόνα 11. Αποτελέσματα του PySpark Random Forest Pipeline.

Το PySpark pipeline φόρτωσε το dataset, μετέτρεψε τις κατηγορικές μεταβλητές με StringIndexer και OneHotEncoder, δημιούργησε το διάνυσμα χαρακτηριστικών με VectorAssembler και εκπάιδευσε Random Forest Classifier. Το αποτέλεσμα δείχνει ότι η διαδικασία μπορεί να εφαρμοστεί σε κατανεμημένο περιβάλλον και να κλιμακωθεί σε μεγαλύτερα τραπεζικά δεδομένα.

9. Σύγκριση Μοντέλων

Το καλύτερο μοντέλο ήταν το Decision Tree, επειδή πέτυχε το υψηλότερο F1-score, δηλαδή την καλύτερη ισορροπία μεταξύ Precision και Recall. Παρότι το Neural Network είχε το υψηλότερο Accuracy, δεν επιλέχθηκε ως καλύτερο, επειδή είχε πολύ χαμηλό Recall και F1-score, γεγονός που δείχνει ότι δεν εντόπιζε αρκετούς από τους πελάτες που πραγματικά αποδέχθηκαν την προσφορά.



Εικόνα 12. Σύγκριση μοντέλων με βάση το F1-score.

Το καλύτερο μοντέλο επιλέχθηκε κυρίως με βάση το F1-score και το ROC-AUC, επειδή το dataset παρουσιάζει ανισορροπία στις κλάσεις και το Accuracy δεν είναι αρκετό από μόνο του.

10. Συμπεράσματα

Η εργασία έδειξε ότι η πρόβλεψη αποδοχής τραπεζικής προθεσμιακής κατάθεσης αποτελεί ένα ρεαλιστικό πρόβλημα Data Mining με πρακτική επιχειρησιακή αξία. Τα αποτελέσματα μπορούν να βοηθήσουν μια τράπεζα να στοχεύσει πιο αποτελεσματικά τους πελάτες που έχουν μεγαλύτερη πιθανότητα ανταπόκρισης, μειώνοντας το κόστος των καμπανιών.

Η ανάλυση ανέδειξε επίσης τη σημασία του preprocessing, της σωστής αξιολόγησης σε imbalanced datasets και της αποφυγής data leakage. Το clustering πρόσφερε επιπλέον πληροφορία για ομάδες πελατών, ενώ η προσέγγιση PySpark έδειξε δυνατότητα κλιμάκωσης σε μεγαλύτερα δεδομένα.

Βιβλιογραφία

- UCI Machine Learning Repository. Bank Marketing Dataset. <https://archive.ics.uci.edu/dataset/222/bank+marketing>
- Moro, S., Cortez, P., & Rita, P. (2014). A data-driven approach to predict the success of bank telemarketing. Decision Support Systems.
- Scikit-learn Documentation. <https://scikit-learn.org/stable/>
- Apache Spark MLlib Documentation. <https://spark.apache.org/docs/latest/ml-guide.html>